Presentation Script ও বিস্তারিত পড়াশোনা — Load Shedding (CSE 492)

Oct 31, 2026 · @Someone

কীভাবে ব্যবহার করবেন

এই document-এ presentation-এ যা বলবেন আর নিজের পড়ার বিস্তারিত, দুটোই এক জায়গায় আছে। প্রতিটা slide-এর অংশে আগে একটা টেবিল: বামে বাংলা, ডানে একই কথা English-এ; প্রতিটা সারি একটা করে কথা বলার অংশ। Presentation English-এ হলে ডানের কলাম পড়বেন, বাংলায় হলে বামেরটা।

টেবিলের পরে আছে **"পেছনের বিস্তারিত"**: প্রতিটা সংখ্যা কোথা থেকে এলো, প্রতিটা concept-এর মানে কী, আর কেন এভাবে করা হয়েছে। এই অংশ slide-এ বলার জন্য নয়, নিজে বোঝার আর teacher-এর প্রশ্নের উত্তর দেওয়ার জন্য। পড়ার ক্রম: Slide 2 আর 3-এর বিস্তারিত আগে ভালোভাবে বুঝুন, কারণ বাকি সব এর উপর দাঁড়িয়ে। শেষে "নিজেকে যাচাই" অংশের প্রশ্নগুলো উত্তর না দেখে নিজে বলার চেষ্টা করুন।

আরও গভীরে (notebook-এর প্রতিটা figure, পুরো paper খসড়া) পড়তে Study Book doc-টা দেখুন।

Slide	বিষয়	সময়
1	Cover	30 সেকেন্ড
2	Problem ও চারটা প্রশ্ন	1 মিনিট
3	Methodology diagram	2 মিনিট
4	Results	1.5 মিনিট
5	Who bears it ও সারকথা	1.5 মিনিট
মোট		**প্রায় 6.5 মিনিট**

তিনটা নিয়ম: (১) slide থেকে পড়বেন না, teacher-এর দিকে তাকিয়ে বলুন; (২) সংখ্যা বলার সময় slide-এর সংখ্যাটাতে ইশারা করুন; (৩) "significant নয়" কথাটা লুকাবেন না, আত্মবিশ্বাসের সাথে বলুন।

Slide 1 — Cover (30 সেকেন্ড)

Slide-এ যা আছে: title "Predicting Load Shedding in Bangladesh", subtitle, আপনার নাম ও ID, course teacher, UITS।

বাংলা	English
আসসালামু আলাইকুম। আমি Md. Shoyaif Rahman। আজ আমার বিষয় "Predicting Load Shedding in Bangladesh"।	Good morning. I am Md. Shoyaif Rahman. My topic today is "Predicting Load Shedding in Bangladesh".
এক বাক্যে: আজকের grid-এর অবস্থা দেখে আমি predict করেছি আগামীকাল উল্লেখযোগ্য load shedding হবে কিনা, কেন হয় তা ব্যাখ্যা করেছি, আর কোন অঞ্চল বেশি কষ্ট পায় তা মেপেছি।	In one sentence: using today's grid data, I predict whether there will be significant load shedding tomorrow, explain why it happens, and measure which regions suffer most.
"Two crises" মানে 2022–24-এর সংকট আর 2026-এর নতুন সংকট; "nine zones" মানে BPDB-এর নয়টা বিতরণ অঞ্চল।	"Two crises" means the 2022–24 crisis and the new 2026 crisis; "nine zones" means BPDB's nine distribution regions.

পেছনের বিস্তারিত: title আর research-এর ধরন

Title-এর প্রতিটা অংশ

অংশ	মানে	কোন কাজ
Predicting	আগে থেকে বলা (এখানে এক দিন আগে)	NB03
Load Shedding	চাহিদার চেয়ে সরবরাহ কম হলে ইচ্ছা করে বিদ্যুৎ বন্ধ রাখা	পুরো research
Explainable	Model কেন এমন বলল, সেটা বোঝানো যায়	NB04 (SHAP)
Early warning	ঘটনার আগে সতর্কতা	NB03, NB05
Gradient boosting	অনেক ছোট decision tree পরপর জোড়া দেওয়া ML পদ্ধতি (XGBoost)	NB03
SHAP	প্রতিটা prediction-এ কোন input কতটা অবদান রাখল, তার হিসাব	NB04
Two crises	2022–24 আর 2026-এর দুটো আলাদা সংকট	NB07
Nine zones	BPDB-এর নয়টা বিতরণ অঞ্চল: Dhaka, Chattogram, Cumilla, Mymensingh, Sylhet, Khulna, Barishal, Rajshahi, Rangpur	NB06, NB08

এটা কোন ধরনের research?

- **Quantitative:** সব কিছু সংখ্যা দিয়ে মাপা।

- **Retrospective, secondary data:** নিজে data সংগ্রহ করিনি, আগে প্রকাশিত public data ব্যবহার করেছি।
- **Applied / empirical ML:** নতুন algorithm বানাইনি; পরিচিত algorithm একটা বাস্তব সমস্যায় সৎভাবে পরীক্ষা করেছি।
- Guideline-এর CSE design টেবিল অনুযায়ী এটা **Experiment / benchmark** (model বনাম baseline, public dataset-এ)।

কেউ জিজ্ঞেস করলে: "আমার contribution নতুন algorithm নয়, বরং একটা বাস্তব সমস্যার সৎ ও ব্যাখ্যাযোগ্য বিশ্লেষণ।"

Slide 2 — The problem (1 মিনিট)

Slide-এ যা আছে: 72% (2023), চারটা RQ card, নিচে prediction target।

বাংলা	English
2022 সালের মাঝামাঝি থেকে Bangladesh-এ আবার বড় আকারের load shedding শুরু হয়েছে।	Since mid-2022, large-scale load shedding has returned to Bangladesh.
2023 সালে বছরের 72% দিনে 100 MW-এর বেশি load shedding হয়েছে; 2021-এ এটা ছিল মাত্র 0.5%।	In 2023, 72% of days had more than 100 MW of load shedding; in 2021 it was only 0.5%.
মূল কারণ জ্বালানির অভাব: gas আর LNG কম থাকায় power plant বসে থাকে।	The main cause is fuel shortage: without enough gas and LNG, power plants sit idle.
100 MW মানে কোনো এক ঘণ্টায় চাহিদার চেয়ে সরবরাহ 100 MW কম, মোটামুটি এক থেকে দুই লাখ বাসার বিদ্যুৎের সমান।	100 MW means supply fell 100 MW short of demand in some hour, roughly the load of one to two hundred thousand homes.
আমি সমস্যাটাকে চারটা প্রশ্নে ভাগ করেছি: কখন হয়, কেন হয়, কোথায় বেশি হয়, আর এক দিন আগে বলা যায় কিনা।	I split the problem into four questions: when, why, where, and can we predict it a day ahead.
মূল target: আগামীকালের সবচেয়ে বড় ঘণ্টার load shedding কি 100 MW ছাড়াবে? উত্তর হ্যাঁ বা না, তাই এটা একটা classification সমস্যা।	The target: will tomorrow's highest hourly load shedding exceed 100 MW? The answer is yes or no, so it is a classification problem.

পেছনের বিস্তারিত: সমস্যা, target আর প্রশ্ন

Load shedding কী আর কেন হয়

Load shedding হলো যখন চাহিদা (demand) সরবরাহের (generation) চেয়ে বেশি হয়, তখন grid ভেঙে পড়া ঠেকাতে ইচ্ছা করে কিছু এলাকার বিদ্যুৎ বন্ধ রাখা। উপমা: একটা পানির ট্যাঙ্ক থেকে দশ বাসায় পানি যায়; ট্যাঙ্কে কম পানি এলে কয়েকটা বাসার কল কিছুক্ষণ বন্ধ রাখতে হয়।

কারণগুলো দুই ভাগে:

দিক	কারণ	আমাদের কোন feature
চাহিদা বাড়ে	গরমে fan, AC, সেচ পাম্প	তাপমাত্রা, demand
সরবরাহ কমে	Gas/LNG-এর অভাব, দামি liquid fuel, coal শেষ, plant মেরামত	fuel mix, supply constraint
সময়ের গঠন	ছুটি, Eid, Ramadan-এ চাহিদার ধরন বদলায়	calendar

MW আর MWh

- **MW (megawatt):** এক মুহূর্তে কত বিদ্যুৎ চলছে, গাড়ির speedometer-এর মতো।
- **MWh (megawatt-hour):** মোট কত শক্তি, গাড়ি কত কিলোমিটার গেল তার মতো। 1,000 MW দুই ঘণ্টা কাটা = 2,000 MWh।
- 100 MW ≈ এক থেকে দুই লাখ বাসার একসাথে চলা বিদ্যুৎ (প্রতি বাসায় 0.5–1 kW ধরলে; মোটা হিসাব)। দেশের peak demand ~13,000–16,000 MW, তাই 100 MW মোটের 1%-এর কম।

Slide-এর সংখ্যা কোথা থেকে

বছর	100 MW+ দিন	মোট load shedding
2021	0.5%	0.6 GWh
2022	32.9%	1,836 GWh
2023	71.8%	2,707 GWh
2024	68.6%	2,167 GWh
2025	38.6%	377 GWh

(PGCB hourly data, NB01, table `t05_annual_summary.csv`) আরও দুটো প্যাটার্ন: সবচেয়ে বেশি load shedding September-এ (গড় 829 MW), সবচেয়ে কম December-এ; ঘণ্টার মধ্যে রাত ১টায় সবচেয়ে বেশি। এগুলো RQ1-এর উত্তর।

Target আর classification

- **Target:** কালকের ২৪ ঘণ্টার মধ্যে সবচেয়ে বড় load shedding যদি 100 MW-এর বেশি হয় → 1, না হলে → 0।
- উত্তর দুটোর একটা (হ্যাঁ/না), তাই এটা **binary classification**। সংখ্যা predict করলে (কত MWh) সেটা হতো **regression**, যেটা secondary task হিসেবে করা হয়েছিল কিন্তু সেখানে model persistence-এর চেয়ে খারাপ ছিল (757 বনাম 710 MWh error)।

- Model সরাসরি 0/1 দেয় না, একটা **probability** দেয় (যেমন 0.82)। একটা **threshold**-এর উপরে হলে "হ্যাঁ" ধরা হয়।

চারটা research question

RQ	প্রশ্ন	উত্তর কোথায়
RQ1	কখন হয়?	NB01 (EDA)
RQ2	কেন হয়?	NB04 (SHAP)
RQ3	কোথায় বেশি?	NB06, NB08
RQ4	আগে বলা যায়?	NB03, NB05, NB07

RQ4-এ formal **hypothesis** আছে: H0 = model আর persistence সমান; H1 = model ভালো। বাকি তিনটা exploratory, তাই hypothesis লাগে না।

Slide 3 — Methodology diagram (2 মিনিট)

Slide-এ যা আছে: তিন সারির methodology diagram, মোট ১০টা ধাপ। উপরের সারি data তৈরি (ধাপ ১–৪), মাঝের সারি model (ধাপ ৫–৭; ৭ নম্বর বাক্স কমলা রঙে চিহ্নিত), নিচের সারি তিনটা উত্তর (ধাপ ৮–১০, হালকা নীল)। তীর ধরে আঙুল দিয়ে দেখাতে দেখাতে বলুন; প্রতিটা বাক্সে একটা ছোট লাইন আছে, সেটা পড়বেন না, ব্যাখ্যা করবেন।

বাংলা	English
এই diagram-টা আমার পুরো কাজের নকশা। সাপের মতো পড়বেন: উপরের সারি বাম থেকে ডানে, তারপর নিচে নেমে মাঝের সারি ডান থেকে বামে, শেষে নিচের সারি।	This diagram is the full design of my work. Read it like a snake: the top row left to right, then down, the middle row right to left, and finally the bottom row.
উপরের সারি, data তৈরি। ধাপ ১: চারটা public dataset, PGCB-এর ঘণ্টাভিত্তিক grid data আর BPDB-এর দৈনিক report, 2015 থেকে 2026। ধাপ ২: একই data-এর দুটো আলাদা release 99.9% ঘণ্টায় মিলেছে, তাই data বিশ্বাসযোগ্য; ১০৯টা ভুল সারি বাদ দিয়েছি।	**Row 1 builds the data.** Step 1: four public datasets, PGCB hourly grid records and BPDB daily reports, from 2015 to 2026. Step 2: two independent releases of the same data matched for 99.9% of hours, so the data are reliable; I removed 109 bad rows.
ধাপ ৩: target একটা হ্যাঁ/না প্রশ্ন: আগামীকালের সবচেয়ে বড় ঘণ্টার load shedding কি 100 MW ছাড়াবে? ধাপ ৪: ৫৭টা input, যেমন আজকের load shedding, demand, জ্বালানি, তাপমাত্রা, ছুটি; সবই আজকের data, তাই ভবিষ্যতের তথ্য ঢোকে না।	Step 3: the target is a yes/no question: will tomorrow's highest hourly load shedding exceed 100 MW? Step 4: 57 inputs such as today's load shedding, demand, fuel, temperature and holidays. All come from today, so no future information leaks in.

বাংলা	English
মাঝের সারি, model। ধাপ ৫: data সময় অনুযায়ী ভাগ করেছি, shuffle করিনি: train 2022–24, validate 2024-এর শেষ ছয় মাস, test জানুয়ারি 2025 থেকে মার্চ 2026, যেটা মাত্র একবার খোলা হয়েছে। ধাপ ৬: চারটা model, Optuna দিয়ে tune; XGBoost সবচেয়ে ভালো।	**Row 2 trains and tests the model.** Step 5: I split the data by time and never shuffled it: train 2022–24, validate the second half of 2024, test January 2025 to March 2026, opened only once. Step 6: four models tuned with Optuna; XGBoost was best.
ধাপ ৭, কমলা বাক্স: প্রতিটা ফল সহজ নিয়ম "আগামীকাল আজকের মতোই হবে"-এর সাথে তুলনা করেছি, PR-AUC, McNemar test আর bootstrap দিয়ে। Model এই নিয়মকে না হারালে তার কোনো মূল্য নেই, তাই এটাই আমার fair test।	Step 7, the orange box: every result is compared with the simple rule "tomorrow will be the same as today", using PR-AUC, the McNemar test and bootstrap. A model is only useful if it beats this rule, so this is my fair test.
নিচের সারি, উত্তর। ধাপ ৮: SHAP দিয়ে কেন ঝুঁকি বাড়ে (RQ2)। ধাপ ৯: একটা crisis-এ শেখা model নতুন 2026 crisis-এ কাজ করে কিনা (RQ4)। ধাপ ১০: নয়টা zone-এর মধ্যে কে বেশি বোঝা বহন করে (RQ3)। পরের দুই slide-এ এগুলোর ফল দেখাব।	**Row 3 gives the answers.** Step 8: SHAP shows why the risk rises (RQ2). Step 9: does a model trained in one crisis work in the new 2026 crisis (RQ4)? Step 10: which of the nine zones bears more of the cuts (RQ3)? I will show these results in the next two slides.

পেছনের বিস্তারিত: method-এর প্রতিটা ধাপ

Diagram কীভাবে পড়বেন

Slide-এর diagram-এ ১০টা বাক্স তিন সারিতে সাজানো। এক লাইনে ১০টা বাক্স ধরে না, তাই সাপের মতো সাজানো: উপরের সারি বাম→ডান, ৪ নম্বর থেকে নিচে নেমে মাঝের সারি ডান→বাম, তারপর ৭ নম্বর থেকে তিনটা শাখা নিচের সারিতে।

সারি	ধাপ	কী হয়	কোন প্রশ্নের উত্তর / কোথা থেকে
উপরের	১–৪	Data সংগ্রহ, যাচাই, target ঠিক করা, feature বানানো	RQ1 (কখন হয়) এই data থেকেই EDA দিয়ে, NB01
মাঝের	৫	সময় অনুযায়ী train / validate / test ভাগ	Leakage ঠেকানো
মাঝের	৬	LR, RF, XGBoost, LightGBM; Optuna দিয়ে tune	NB03
মাঝের	৭	Persistence-এর সাথে তুলনা: PR-AUC, McNemar, bootstrap	RQ4 (আগে বলা যায় কিনা), NB03, NB05
নিচের	৮	SHAP, আর load shedding ইতিহাস বাদ দিয়ে structural model	RQ2 (কেন হয়), NB04

সারি	ধাপ	কী হয়	কোন প্রশ্নের উত্তর / কোথা থেকে
নিচের	৯	2022–24-এ শেখা frozen model 2025 আর 2026-এ পরীক্ষা (BPDB data, LightGBM)	RQ4, NB07
নিচের	১০	Disproportionality, Gini, order of shedding, zone premium	RQ3 (কোথায় বেশি), NB06, NB08

তিনটা জিনিস মনে রাখুন:

- **৭ নম্বর বাক্স কেন রঙিন:** এই কাজের মূল দাবি হলো সৎ তুলনা। আগের Bangladeshi কাজগুলো persistence-এর সাথে তুলনা দেখায়নি; আমাদের নতুনত্বের প্রথম অংশ এখানেই।
- **নিচের তিনটা বাক্স কেন ৭-এর পরে:** model পরীক্ষায় টেকার পরেই তাকে ব্যাখ্যা করা (SHAP) বা নতুন crisis-এ পরীক্ষা করা অর্থবহ। তবে ১০ নম্বরের বেশিরভাগ অংশ (disproportionality, Gini, order of shedding) model ছাড়াই data-র সরাসরি হিসাব; শুধু zone premium-এর জন্য আলাদা zone model লাগে। Teacher জিজ্ঞেস করলে এটা সৎভাবে বলুন।
- **RQ1-এর আলাদা বাক্স নেই কেন:** "কখন হয়" প্রশ্নের উত্তর model লাগে না; উপরের সারির data থেকে বছর, মাস আর ঘণ্টা অনুযায়ী গুনে (EDA) পাওয়া যায়। Slide 2-এর 72% সংখ্যাটা সেখান থেকেই।

ধাপ ১: Data

Dataset	কী	সময়	কেন দরকার
PGCB hourly (Mendeley)	প্রতি ঘণ্টার generation, demand, load shedding, fuel mix	2015–2026 (Mar)	মূল national model
PGCB hourly (UCI)	একই data-এর আলাদা release	আংশিক	যাচাইয়ের জন্য
BPDB daily (Hossain et al. 2025)	জ্বালানি সংকট, Dhaka-র তাপমাত্রা, zone-ওয়ারি সংখ্যা	2019–2024	Feature ও zone বিশ্লেষণ
BPDB daily (extended)	উপরেরটার বর্ধিত রূপ	2026 (Aug) পর্যন্ত	2026 crisis পরীক্ষা

PGCB = Power Grid Company of Bangladesh (grid চালায়); BPDB = Bangladesh Power Development Board (উৎপাদন ও পরিকল্পনা)।

ধাপ ২: Clean & verify

যাচাই: UCI-এর সময়ের সাথে ১ ঘণ্টা যোগ করলে দুটো release-এর 99.89% ঘণ্টা হুবহু মেলে। অর্থাৎ একই data, শুধু ঘড়ির হিসাবে এক ঘণ্টার পার্থক্য। BPDB আর PGCB-এর দৈনিক generation-এর correlation 0.957–0.999।

তিনটা cleaning নিয়ম:

1. **Range check:** demand বা generation 1,000–20,000 MW-এর বাইরে হলে অসম্ভব।

2. **Spike:** একটা সংখ্যা আশেপাশের দিনগুলোর একই ঘণ্টার median থেকে 50%-এর বেশি লাফ দিল, কিন্তু অন্যটা নড়ল না। দুটোই একসাথে নামলে সেটা বাস্তব ঘটনা (যেমন cyclone), তাই বাদ নয়, flag।
3. **LS consistency:** load shedding ঘাটতির চেয়ে অনেক বেশি (> 1.2 × deficit + 50 MW) হলে ভুল লেখা।

ফল: 109টা সারি (0.115%) বাদ; জানা 11টা typo-র 11টাই ধরা পড়েছে। 21টা cyclone দিন আর 4 Oct 2022-এর grid failure রাখা হয়েছে কিন্তু flag করে। তারপর ঘণ্টার data থেকে দিনের সর্বোচ্চ, গড় আর মোট বানানো হয়েছে।

ধাপ ৩: Features আর leakage

Feature = model-এর সূত্র; মোট 57টা, 8 দলে:

Group	সংখ্যা	উদাহরণ
Load shedding ইতিহাস	13	আজকের সর্বোচ্চ, গত ৭/১৪/৩০ দিনের সর্বোচ্চ
Demand ও generation	7	peak demand, peak gap
Fuel mix	13	gas, liquid fuel, coal কত ও কত %
Supply constraint	5	gas limitation MW, coal limitation
তাপমাত্রা (আজ)	2	Dhaka সর্বোচ্চ
তাপমাত্রা (কাল)	2	কালকের সর্বোচ্চ
Calendar	13	সপ্তাহের দিন, ছুটি, Eid, Ramadan
Event	2	cyclone, 2024-এর অস্থিরতা

Leakage: পরীক্ষার হলে উত্তরপত্র হাতে পেলে ছাত্র ১০০ পাবে, কিন্তু কিছুই শেখেনি। Model-কে কালকের এমন তথ্য দিলে, যা আজ জানা সম্ভব নয়, সে দারুণ দেখাবে কিন্তু বাস্তবে কাজ করবে না। আমাদের সব feature আজকের; ব্যতিক্রম কালকের calendar (আগেই জানা) আর কালকের তাপমাত্রা (পূর্বাভাস থাকে, তবে আমরা আসল মান নিয়েছি, এটা limitation)।

ধাপ ৪: Model

Model	সহজ ব্যাখ্যা
Logistic regression	সব feature-এর ওজন দিয়ে যোগ, তারপর 0–1 probability-তে রূপান্তর; সবচেয়ে সহজ
Random forest	অনেকগুলো decision tree আলাদাভাবে বানিয়ে ভোট নেওয়া

Model	সহজ ব্যাখ্যা
XGBoost / LightGBM	Gradient boosting: tree একটার পর একটা, প্রতিটা আগেরগুলোর ভুল শোধরায়

Gradient boosting-এর উপমা: একজন ছাত্র প্রথমবার পরীক্ষা দিল, কিছু ভুল করল; দ্বিতীয়বার শুধু সেই ভুলগুলোতে মন দিল; তৃতীয়বার বাকি ভুলগুলোতে। আমাদের XGBoost-এ 600টা ছোট tree (গভীরতা 2), learning rate 0.011।

Optuna: model-এর setting (hyperparameter, যেমন tree কত গভীর) হাতে না বেছে স্বয়ংক্রিয়ভাবে খোঁজা। আগের চেষ্টাগুলো দেখে পরের চেষ্টা বাছে (TPE পদ্ধতি), model প্রতি 30–80 বার।

Expanding-window cross-validation: training-এর ভেতরেই ৫ বার পরীক্ষা: অতীত থেকে শিখে পরের তিন মাসে পরীক্ষা, প্রতিবার শেখার অংশ বাড়ে।

Threshold বাছাই: validation-এ যে threshold-এ F1 সবচেয়ে বেশি, সেটা = 0.76। Probability ⩾ 0.76 হলে "হ্যাঁ"।

ধাপ ৫: Time split

ভাগ	সময়	দিন	Positive	উপমা
Train	Jul 2022 – Jun 2024	730	70%	ক্লাসে পড়া
Validation	Jul – Dec 2024	184	65%	মডেল টেস্ট
Test	Jan 2025 – Mar 2026	432	37%	ফাইনাল, একবারই

কেন random নয়: বাস্তবে আমরা অতীত দেখে ভবিষ্যৎ বলি। Random ভাগ করলে model 2025 থেকে শিখে 2023 predict করত, যা বাস্তবে অসম্ভব। লক্ষ্য করুন: 2022–24-এর data নেওয়া হয়েছে কারণ 2021-এর আগে প্রায় কোনো load shedding ছিল না, শেখার কিছু ছিল না।

Slide 4 — Results (1.5 মিনিট)

Slide-এ যা আছে: বামে model বনাম "same as today" table (চার সারি, Proven? কলাম), ডানে ঝুঁকির তিনটা সীমা।

বাংলা	English
বামের table-এ model আর সহজ নিয়মের তুলনা। পরীক্ষা 2025 থেকে 2026-এর data-তে, যা model আগে কখনো দেখেনি।	The table on the left compares the model with the simple rule, on 2025–2026 data the model had never seen.
ঝুঁকিপূর্ণ দিন সাজানোয় model স্পষ্টভাবে ভালো: 0.832 বনাম 0.608।	The model ranks risky days clearly better: 0.832 versus 0.608.

বাংলা	English
যেদিন অবস্থা বদলায়, যেমন load shedding শুরু বা থামার দিন, সেখানে model 37.6% ঠিক বলেছে; সহজ নিয়ম একটাও না।	On turning-point days, when load shedding starts or stops, the model is right 37.6% of the time; the simple rule never is.
তবে প্রতিদিনের accuracy-তে পার্থক্য ছোট (0.810 বনাম 0.785) আর statistically প্রমাণিত নয়, p = 0.19। কারণ load shedding টানা কয়েকদিন চলে, তাই "আজকের মতোই কাল" নিয়মও অনেক সময় ঠিক হয়।	But everyday accuracy is only slightly higher, 0.810 versus 0.785, and not statistically significant, p = 0.19. Load shedding runs in streaks, so "same as today" is often right too.
নতুন 2026 crisis-এ model-কে কোনো পরিবর্তন ছাড়া চালিয়েছি: 0.893 বনাম 0.860, এখানেও প্রমাণিত নয় (p = 0.12)।	In the new 2026 crisis, the unchanged model reached 0.893 versus 0.860, again not significant (p = 0.12).
ডানে: SHAP বলছে ঝুঁকি বাড়ে যখন কালকের তাপমাত্রা 32.5°C-এর বেশি, demand 12,800 MW-এর বেশি, আর সরবরাহে 100 MW-এর বেশি ঘাটতি।	On the right: SHAP shows the risk rises when tomorrow is hotter than 32.5°C, demand exceeds 12,800 MW, and supply falls more than 100 MW short.
এক কথায়: model ঝুঁকিপূর্ণ দিন আর অবস্থা বদলের দিন ধরতে ভালো, প্রতিদিনের হ্যাঁ/না-তে নয়।	In short: the model is good at risky days and turning points, not at every single day.

পেছনের বিস্তারিত: result কীভাবে মাপা হলো

Confusion matrix আর মূল metric

প্রতিটা দিনের prediction চার ভাগের একটাতে পড়ে:

	আসলে load shedding হয়েছে	আসলে হয়নি
Model বলেছে "হ্যাঁ"	TP (সঠিক warning)	FP (false alarm)
Model বলেছে "না"	FN (miss)	TN (সঠিক শান্ত)

Metric	সূত্র	কী বলে
Accuracy	(TP + TN) ÷ সব	মোট কত দিন ঠিক
Precision	TP ÷ (TP + FP)	warning দিলে কতবার সত্যি হয়
Recall	TP ÷ (TP + FN)	আসল ঘটনার কতটা ধরা পড়ে
F1	Precision আর Recall-এর harmonic গড়	দুটোর ভারসাম্য

Metric	সূত্র	কী বলে
ROC-AUC	একটা load shedding দিন একটা স্বাভাবিক দিনের চেয়ে বেশি score পাওয়ার সম্ভাবনা	সাজানোর দক্ষতা
PR-AUC	সব threshold-এ precision বনাম recall curve-এর নিচের এলাকা	ঝুঁকিপূর্ণ দিন উপরে সাজানোর দক্ষতা

কেন PR-AUC দিয়ে model বাছা: এটা কোনো একটা threshold-এর ওপর নির্ভর করে না, আর positive দিন কম থাকলেও (test-এ 37%) সৎ ছবি দেয়। সাবধানতা: persistence শুধু 0/1 দেয়, probability নয়, তাই তার PR-AUC তুলনাটা কিছুটা দুর্বল; reviewer এটা ধরতে পারেন।

পুরো test result (432 দিন)

Model	PR-AUC	ROC-AUC	F1	Accuracy	Transition day
Persistence	0.608	0.768	0.707	0.785	0%
Seasonal naive	0.414	0.578	0.464	0.609	48.4%
Logistic regression	0.800	0.862	0.706	0.771	39.8%
Random forest	0.819	0.886	0.751	0.778	38.7%
XGBoost	**0.832**	**0.893**	0.725	**0.810**	37.6%
LightGBM	0.812	0.883	0.715	0.748	38.7%

লক্ষ্য করুন: transition day-এ seasonal naive ("গত সপ্তাহের এই দিনের মতো") 48.4% পায়, XGBoost-এর চেয়ে বেশি, কিন্তু সামগ্রিক accuracy মাত্র 0.609। এটা লুকাবেন না।

Persistence আর transition day

- **Persistence** = "আজ যা, কালও তা"। Load shedding টানা চলে, তাই এই নিয়ম 78.5% ঠিক।
- **Transition day** = যেদিন কালকের অবস্থা আজকের থেকে আলাদা (শুরু = onset, থামা = recovery)। Test-এ 93টা (21.5%)। Persistence এই দিনগুলোতে সংজ্ঞা অনুযায়ীই সবসময় ভুল। XGBoost ঠিক: 37.6% (onset 28%, recovery 48%)।

Significance test

McNemar test: একই দিনগুলোতে দুটো পদ্ধতির ভুল তুলনা করে। শুধু যে দিনগুলোতে একজন ঠিক আর অন্যজন ভুল, সেগুলো গোনে: model একা ঠিক 35 দিন, persistence একা ঠিক 24 দিন। দুটো সমান হলে এই ভাগ আনুমানিক 50–50 হতো; 35 বনাম 24 কাকতালীয়ভাবেও হতে পারে, তাই p = 0.19।

p-value: দুটো আসলে সমান হলেও এমন পার্থক্য দেখার সম্ভাবনা। সীমা 0.05; এর নিচে হলে "significant"।

Block bootstrap: test-এর দিনগুলো ১৪ দিনের টুকরোয় কেটে ২,০০০ বার এলোমেলো বেছে পার্থক্য আবার হিসাব। টুকরো করা হয় কারণ পাশাপাশি দিন একে অপরের সাথে সম্পর্কিত। ফল 95% confidence interval:

পার্থক্য (model − persistence)	মান	95% CI	শূন্য আছে?
PR-AUC	+0.224	0.164 – 0.282	না → প্রমাণিত
Transition accuracy	+0.376	0.304 – 0.446	না → প্রমাণিত
Accuracy	+0.026	−0.014 – 0.060	হ্যাঁ → প্রমাণিত নয়

Validation 0.984, test 0.832: এত পার্থক্য কেন?

এটা **regime shift**: 2025-এ অবস্থা বদলে গেছে (positive দিন 65% → 37%, transition দিন 10% → 21.5%)। Persistence-এরও একই পতন (0.898 → 0.608)। Model খুব সরল (tree গভীরতা 2) আর seed বদলালে ফল প্রায় একই, তাই এটা overfitting নয়।

Two-crisis test (NB07)

BPDB data-তে model 2022–24 দিয়ে শিখিয়ে freeze, তারপর দুই সময়ে পরীক্ষা (LightGBM, threshold 0.48):

Test	Model	PR-AUC	Accuracy	Onset ধরেছে
2025 (শান্ত)	Persistence	0.403	0.829	0/31
2025	Frozen	0.628	0.798	18/31
2025	প্রতি মাসে retrain	0.596	0.804	5/31
2026 (crisis)	Persistence	0.807	0.860	0/16
2026	Frozen	0.925	0.893	8/16
2026	প্রতি মাসে retrain	0.927	0.860	4/16

2026-এর চারটা বড় episode-এর শুরু: 2 April (p = 0.481, threshold-এর ঠিক উপরে) আর 1 June (0.671)-এ warning; 20 January আর 5 May miss। **Crisis memory:** শান্ত 2025 শিখে retrain করা model কম সতর্ক হয়ে গিয়েছিল। একটা crisis-এর পর্যবেক্ষণ, hypothesis হিসেবে বলবেন।

SHAP: কেন ঝুঁকি বাড়ে

উপমা: একটা দল ৩ গোল দিল; কোন খেলোয়াড়ের কতটা কৃতিত্ব? SHAP (Shapley value, game theory) প্রতিটা prediction-কে feature-গুলোর মধ্যে এভাবে ন্যায্যভাবে ভাগ করে।

Feature group	Full model	ইতিহাস ছাড়া model
Load shedding ইতিহাস	47.7%	—

Feature group	Full model	ইতিহাস ছাড়া model
Demand ও generation	14.9%	49.4%
Fuel mix	14.4%	21.5%
Calendar	11.3%	15.9%
কালকের তাপমাত্রা	7.7%	5.7%
Supply constraint	1.7%	4.7%

কেন দ্বিতীয় (structural) model: full model-এ অর্ধেক কৃতিত্ব "গতকালের load shedding"-এর, যা নতুন কিছু শেখায় না। ইতিহাস বাদ দিলে আসল কারণ দেখা যায়; সেই model-এর PR-AUC 0.775, তাও persistence-এর চেয়ে বেশি। Dependence plot-এ ঝুঁকি লাফ দেয়: কালকের তাপমাত্রা ~32.5°C, demand ~12,800 MW (13,800-এ গিয়ে থেমে যায়), gap ~100 MW ছাড়ালে। SHAP কারণ প্রমাণ করে না, শুধু model-এর নির্ভরতা দেখায়।

Robustness: ফল কতটা টেকসই

পরীক্ষা	ফল
300 / 500 MW target	Model-এর F1 persistence-এর চেয়ে কম (0.609 vs 0.636; 0.303 vs 0.440)
Load shedding ইতিহাস বাদ	PR-AUC − 0.058
কালকের তাপমাত্রা বাদ	PR-AUC − 0.005
পাঁচটা আলাদা seed	0.828 ± 0.002
Miss-এর খরচ false alarm-এর 5 গুণ ধরলে	threshold 0.18, recall 97%, খরচ persistence-এর চেয়ে 48% কম

Slide 5 — Who bears it ও সারকথা (1.5 মিনিট)

Slide-এ যা আছে: চারটা zone-এর bar (ধূসর = demand-এর ভাগ, কমলা = load shedding-এর ভাগ), ডানে "In short" তিন লাইন।

বাংলা	English
ধূসর bar হলো জাতীয় demand-এ ওই zone-এর ভাগ, কমলা bar হলো জাতীয় load shedding-এ তার ভাগ। ন্যায্য হলে দুটো সমান হতো।	The grey bar is each zone's share of national demand; the orange bar is its share of load shedding. If it were fair, both would be equal.

বাংলা	English
Mymensingh-এর demand মাত্র 8.4%, কিন্তু load shedding 27.5%, অর্থাৎ নিজের ন্যায্য ভাগের 3.3 গুণ।	Mymensingh has only 8.4% of demand but 27.5% of load shedding, 3.3 times its fair share.
উল্টোদিকে Dhaka পায় নিজের ভাগের 0.6 গুণ, Barishal 0.2 গুণ।	In contrast, Dhaka gets 0.6 times its share and Barishal 0.2 times.
ঘাটতি যখন ছোট, তখন কাটা আগে পড়ে Mymensingh-এ: ওই দিনগুলোতে সব কাটার 65% একা Mymensingh-এর।	When the shortfall is small, Mymensingh is cut first: on those days it carries 65% of all load shedding.
ফলে তিনটা সারকথা: ১) load shedding আংশিকভাবে predict করা যায়; ২) গরম, বেশি demand আর সরবরাহের ঘাটতি ঝুঁকি বাড়ায়; ৩) এর বোঝা সব অঞ্চলে সমান নয়।	So, three takeaways: 1) load shedding is partly predictable; 2) heat, high demand and supply gaps raise the risk; 3) the burden is not shared equally.
ধন্যবাদ। আপনার কোনো প্রশ্ন থাকলে বলবেন।	Thank you. I am happy to take your questions.

পেছনের বিস্তারিত: কার উপর বোঝা পড়ে

Disproportionality ratio

সূত্র: R(zone) = (zone-এর load shedding ÷ জাতীয় load shedding) ÷ (zone-এর demand ÷ জাতীয় demand)

R = 1 মানে ন্যায্য ভাগ; 1-এর বেশি মানে বেশি কষ্ট; 1-এর কম মানে সুরক্ষিত। উদাহরণ: Mymensingh = 27.5 ÷ 8.4 = 3.27।

Zone	Demand-এ ভাগ	Load shedding-এ ভাগ	R (2022–24)	R (2025–26)
Mymensingh	8.4%	27.5%	3.27	3.74
Rangpur	6.7%	10.8%	1.61	1.38
Cumilla	9.4%	13.3%	1.41	1.06
Sylhet	4.0%	5.5%	1.38	1.30
Rajshahi	10.4%	8.7%	0.83	0.80
Khulna	12.1%	8.7%	0.72	1.04
Dhaka	36.1%	20.6%	0.57	0.45
Chattogram	10.0%	4.4%	0.44	0.48

Zone	Demand-এ ভাগ	Load shedding-এ ভাগ	R (2022–24)	R (2025–26)
Barishal	3.0%	0.6%	0.20	0.85

Data বিশ্বাসযোগ্য কিনা: প্রতিটা zone-দিনে demand − supply = load shedding সমীকরণ 99.4% মিলেছে।

Lorenz curve আর Gini

অর্থনীতিতে আয়-বৈষম্য মাপার পদ্ধতি। Zone-গুলোকে কম থেকে বেশি intensity (load shedding ÷ demand) অনুযায়ী সাজিয়ে x-এ জমানো demand-এর ভাগ, y-এ জমানো load shedding-এর ভাগ। সব ন্যায্য হলে সোজা কর্ণ রেখা (Gini 0); সব এক জায়গায় হলে Gini 1।

বছর	Gini	জাতীয় intensity
2022 (Jul–Dec)	0.29	3.8%
2023	0.43	1.6%
2024	0.38	1.8%
2025	**0.51**	**0.5%**
2026 (Jan–Aug)	0.35	3.0%

আপাত-বিরোধী ফল: 2025-এ মোট load shedding সবচেয়ে কম, কিন্তু বৈষম্য সবচেয়ে বেশি। কারণ নিচের order of shedding।

Order of shedding

যে দিনগুলোতে জাতীয় load shedding > 0, সেগুলোকে ঘাটতির আকার অনুযায়ী পাঁচ ভাগে ভাগ করে দেখা হয়েছে কোন zone কত ভাগ বহন করে:

জাতীয় ঘাটতি	দিন	Mymensingh-এ কাটা পড়ে (দিনের %)	Mymensingh-এর ভাগ	Dhaka-র ভাগ
1–100 MW	306	76%	65.4%	14.1%
101–300 MW	230	94%	55.1%	15.2%
301–700 MW	186	99%	36.0%	17.3%
701–1,500 MW	117	99%	18.5%	21.2%
> 1,500 MW	37	100%	14.0%	21.6%

অর্থাৎ ঘাটতি ছোট হলে বোঝা প্রায় একা Mymensingh-এর; বড় হলে সবাই কাটা পড়ে। আনুমানিক ক্রম: Mymensingh → Dhaka → Cumilla → Rangpur → Sylhet → Khulna/Rajshahi → Chattogram → Barishal।

Zone premium

প্রশ্ন: Mymensingh-এ কি শুধু গরম বা demand বেশি বলেই বেশি কাটা পড়ে? তাই নয়টা zone-এর প্রতিদিনের data একসাথে নিয়ে (13,293 সারি) একটা model বানানো হয়েছে, যেখানে zone-এর নামও একটা feature। অবস্থা (গরম, demand, গতকালের কাটা) সমান রেখে শুধু নাম থেকে যে বাড়তি ঝুঁকি আসে, সেটাই zone premium (SHAP, log-odds এককে):

Zone	Premium
Mymensingh	+0.48
Cumilla	+0.12
Dhaka	+0.06
Khulna / Rajshahi	−0.06 / −0.08
Chattogram	−0.32
Barishal	−0.42

+0.48 log-odds মানে মোটামুটি odds প্রায় 1.6 গুণ (e^0.48)। এটা causal নয়: transmission line-এর সীমাবদ্ধতার মতো model-এ না থাকা কারণও এর ভেতরে ঢুকে থাকতে পারে। Zone model-এর accuracy persistence-এর প্রায় সমান, তাই এই অংশের মূল্য prediction নয়, ব্যাখ্যা।

Limitation (সৎভাবে বলার জন্য)

1. তাপমাত্রা শুধু Dhaka-র, আর কালকের তাপমাত্রা আসল পূর্বাভাস নয়, পরে মাপা মান।
2. Test period ছোট (432 আর 214 দিন), তাই significance পাওয়া কঠিন।
3. SHAP আর zone premium causal নয়।
4. Official data গ্রামের আসল কাটা কম দেখাতে পারে (খবর অনুযায়ী REB-এর নিজের হিসাব জাতীয় সংখ্যার চেয়ে বেশি)।
5. দৈনিক prediction; কোন ঘণ্টায় কাটা হবে তা নয়।

Teacher যে প্রশ্ন করতে পারেন

প্রতিটা উত্তরের প্রথম বাক্যটাই আসল উত্তর; সময় কম হলে শুধু সেটাই বলুন।

ক. সমস্যা ও গুরুত্ব

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
1. Why is this research important?	এক দিন আগে জানলে grid operator জ্বালানি বা বিকল্প plant প্রস্তুত রাখতে পারে, কারখানা ও হাসপাতাল generator-এর পরিকল্পনা করতে পারে। 2023-এ 72% দিনে load shedding হয়েছে, তাই সমস্যাটা বাস্তব ও বড়।	Knowing a day ahead lets the grid operator prepare fuel or backup plants, and lets factories and hospitals plan generators. 72% of days in 2023 had load shedding, so the problem is real and large.
2. What does "100 MW load shedding" mean?	কোনো এক ঘণ্টায় চাহিদার চেয়ে সরবরাহ 100 MW কম, তাই ইচ্ছা করে ওই পরিমাণ চাহিদা কেটে দেওয়া হয়। মোটামুটি এক থেকে দুই লাখ বাসার সমান।	In some hour, supply was 100 MW below demand, so that much demand was cut on purpose, roughly one to two hundred thousand homes.
3. Why 100 MW and not another threshold?	100 MW-এর নিচে প্রায়ই স্থানীয় ছোট সমস্যা বা noise। 0, 300 আর 500 MW দিয়েও পরীক্ষা করেছি; বড় সীমায় model দুর্বল, এটা paper-এ সৎভাবে লিখেছি।	Below 100 MW it is mostly small local issues or noise. I also tested 0, 300 and 500 MW; the model is weaker at the larger thresholds, and I report that honestly.

খ. Literature review

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
4. Has anyone done this before?	হ্যাঁ, Bangladesh-এ দুটো কাজ আছে (Rahman et al. 2016; Arifuzzaman 2026), আর South Africa-তে একটা (Akinola et al. 2024)। তাই আমি "প্রথম" দাবি করি না।	Yes, there are two Bangladeshi studies (Rahman et al. 2016; Arifuzzaman 2026) and one from South Africa (Akinola et al. 2024). So I do not claim to be the first.

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
5. Then what is new in your work?	তিনটা জিনিস আগের কাজে পাইনি: ১) "আজকের মতোই কাল" baseline-এর সাথে সৎ তুলনা; ২) এক crisis-এ শেখা model নতুন crisis-এ পরীক্ষা; ৩) নয়টা zone-এ বোঝার বৈষম্য মাপা।	Three things I did not find in earlier work: 1) an honest comparison with the "same as today" baseline; 2) testing a model trained in one crisis on a new crisis; 3) measuring the unequal burden across nine zones.

গ. Data ও method

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
6. Where did your data come from? Can we trust it?	PGCB আর BPDB-এর public data। একই data-এর দুটো আলাদা release 99.9% মিলেছে, আর দুই প্রতিষ্ঠানের generation-এর correlation 0.96–0.999।	Public data from PGCB and BPDB. Two releases of the same data matched 99.9%, and the two agencies' generation figures correlate at 0.96–0.999.
7. Why gradient boosting and not deep learning?	Data table আকারে আর মাত্র ~730টা training দিন। এমন data-তে tree-based boosting সাধারণত সমান বা ভালো করে, দ্রুত চলে, আর SHAP দিয়ে সহজে ব্যাখ্যা করা যায়।	The data are tabular with only about 730 training days. Tree-based boosting usually performs as well or better on such data, is fast, and is easy to explain with SHAP.
8. What is persistence, and why compare with it?	"আজ যা হয়েছে, কালও তাই হবে"। Load shedding টানা চলে, তাই এই সহজ নিয়মই 78.5% ঠিক। Model-এর আসল মূল্য তখনই, যখন সে এই নিয়মের চেয়ে বেশি কিছু দেয়।	"Tomorrow will be the same as today." Load shedding runs in streaks, so this simple rule is already 78.5% correct. A model only adds value if it beats this rule.
9. How did you avoid data leakage?	সব feature আজকের data থেকে। Data সময় অনুযায়ী ভাগ করেছি, shuffle করিনি, আর test অংশ সব সিদ্ধান্ত নেওয়ার পর একবারই খুলেছি।	Every feature uses today's data only. I split by time without shuffling, and opened the test period only once, after all choices were fixed.

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
10. You used tomorrow's temperature. Isn't that cheating?	আবহাওয়ার পূর্বাভাস এক দিন আগে পাওয়া যায়, তাই এটা বাস্তবসম্মত। তবে আমি আসল পরিমাপ ব্যবহার করেছি, পূর্বাভাস নয়, এটা limitation। এই feature বাদ দিলেও ফল প্রায় একই থাকে (PR-AUC মাত্র 0.005 কমে)।	Weather forecasts are available a day ahead, so it is realistic. But I used the observed value, not a real forecast, which is a limitation. Removing this feature barely changes the result (PR-AUC drops by only 0.005).

ঘ. Result

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
11. Your accuracy is not significant. So is the model useless?	না। প্রতিদিনের হ্যাঁ/না-তে পার্থক্য প্রমাণিত নয়, কিন্তু ঝুঁকিপূর্ণ দিন সাজানো (0.832 বনাম 0.608) আর অবস্থা বদলের দিন ধরায় (37.6% বনাম 0%) model প্রমাণিতভাবে ভালো। Warning system-এ ঠিক এইগুলোই সবচেয়ে দরকার।	No. The everyday yes/no gain is not proven, but the model is proven better at ranking risky days (0.832 vs 0.608) and at turning-point days (37.6% vs 0%). Those matter most for a warning system.
12. What is a p-value?	দুটো পদ্ধতি আসলে সমান হলেও কাকতালীয়ভাবে এমন পার্থক্য দেখার সম্ভাবনা। p = 0.19 মানে প্রায় 19%; সীমা সাধারণত 5%, তাই প্রমাণিত নয়।	The chance of seeing such a difference by luck if the two methods were actually equal. p = 0.19 means about 19%; the usual cut-off is 5%, so it is not proven.
13. What is SHAP?	Model-এর প্রতিটা prediction-কে input-গুলোর মধ্যে ন্যায্যভাবে ভাগ করে দেখানোর পদ্ধতি, যেমন ফুটবল দলের গোলে কোন খেলোয়াড়ের কতটা অবদান।	A method that fairly splits each prediction among the inputs, like crediting each player for a team's goal.
14. Does SHAP prove that heat causes load shedding?	না। SHAP বলে model কিসের উপর নির্ভর করেছে, কারণ প্রমাণ করে না। তবে গরমে AC-fan-এর demand বাড়ে, তাই ফলটা বাস্তবের সাথে মেলে।	No. SHAP shows what the model relies on, not causation. But heat raises demand for fans and AC, so the result makes physical sense.

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
15. Why did the monthly retrained model do worse in 2026?	সম্ভাব্য কারণ: শান্ত 2025 থেকে শিখে সে ধরে নিয়েছিল "গরম হলেও কাটা হয় না", তাই নতুন crisis-এ কম সতর্ক ছিল। আমি এটাকে "crisis memory" বলি। একটা মাত্র crisis, তাই এটা hypothesis, প্রমাণিত নিয়ম নয়।	A likely reason: learning from calm 2025 taught it that heat no longer means cuts, so it was less alert when the crisis returned. I call this "crisis memory". It rests on one crisis, so it is a hypothesis, not a proven rule.

ঙ. Equity ও limitation

প্রশ্ন	উত্তর (বাংলা)	Answer (English)
16. Why does Mymensingh get so much load shedding?	আমার data দেখায় কতটা বেশি, কিন্তু কারণ প্রমাণ করে না। সম্ভাব্য কারণ: transmission line-এর সীমাবদ্ধতা, কাছাকাছি উৎপাদন কম, বা কোন এলাকা আগে কাটা হবে সেই সিদ্ধান্ত। এগুলো যাচাই করা future work।	My data show how much more, but not why. Possible reasons are transmission limits, little local generation, or decisions about which areas are cut first. Testing these is future work.
17. What is the biggest limitation?	তাপমাত্রা শুধু Dhaka-র, আর আসল পূর্বাভাস নয়। Test period ছোট, তাই significance পাওয়া কঠিন। আর official data গ্রামের আসল কাটা কম দেখাতে পারে।	Temperature is only for Dhaka and is not a real forecast. The test period is short, so significance is hard to reach. And official data may understate rural load shedding.
18. What would you do next?	আসল weather forecast আর zone-ওয়ারি তাপমাত্রা যোগ করা, LNG আমদানির সময়সূচি যোগ করা, আর ঘণ্টা ধরে prediction।	Add real weather forecasts and zone-level temperature, add LNG import schedules, and predict at the hourly level.

মুখস্থ রাখার সংখ্যা

বিষয়	সংখ্যা
100 MW+ load shedding-এর দিন	2021: 0.5% · 2023: 72% · 2025: 39%
Data source মিল	99.9%
Feature	57
Train / Validate / Test	730 / 184 / 432 দিন
Ranking (PR-AUC): model vs persistence	0.832 vs 0.608 (প্রমাণিত)
Turning-point দিন ঠিক	37.6% vs 0% (প্রমাণিত)
Accuracy	0.810 vs 0.785 (p = 0.19, প্রমাণিত নয়)
2026 crisis accuracy	0.893 vs 0.860 (p = 0.12)
ঝুঁকির সীমা	32.5°C · 12,800 MW · 100 MW gap
Mymensingh	demand 8.4%, load shedding 27.5% (×3.3); ছোট ঘাটতিতে 65%
Dhaka / Barishal	×0.6 / ×0.2

নিজেকে যাচাই

উত্তর না দেখে আগে নিজে বলুন, তারপর মিলিয়ে নিন। প্রতিটা পড়া শেষে নিচের ঘরে টিক দিন।

#	প্রশ্ন	সংক্ষিপ্ত উত্তর
1	Target ঠিক কী?	কালকের সবচেয়ে বড় ঘণ্টার load shedding > 100 MW কিনা (হ্যাঁ/না)
2	Classification আর regression-এর পার্থক্য?	Classification = শ্রেণি (হ্যাঁ/না); regression = সংখ্যা (কত MWh)
3	দুটো source কেন?	একটা দিয়ে আরেকটা যাচাই (99.9% মিল), আর BPDB-তে জ্বালানি ও zone-এর তথ্য আছে
4	Leakage কী, কীভাবে এড়ালাম?	ভবিষ্যতের তথ্য input-এ ঢোকা; সব feature আজকের, সময় অনুযায়ী split
5	Data shuffle করিনি কেন?	বাস্তবে অতীত দেখে ভবিষ্যৎ বলা হয়

#	প্রশ্ন	সংক্ষিপ্ত উত্তর
6	Gradient boosting এক লাইনে?	ছোট tree একটার পর একটা, প্রতিটা আগের ভুল শোধরায়
7	Threshold 0.76 কোথা থেকে?	Validation-এ F1 সর্বোচ্চ যেখানে
8	Persistence কেন এত শক্ত?	Load shedding টানা কয়েকদিন চলে; 78.5% ঠিক
9	Model কোথায় প্রমাণিতভাবে ভালো?	Ranking (PR-AUC 0.832 vs 0.608) আর transition day (37.6% vs 0%)
10	Accuracy-র p-value কত, মানে কী?	0.19; 0.05-এর বেশি, তাই প্রমাণিত নয়
11	Validation 0.984 আর test 0.832 কেন আলাদা?	Regime shift: 2025-এ load shedding কমে গিয়েছিল
12	Structural model কী, কেন?	Load shedding ইতিহাস ছাড়া model, আসল কারণ দেখার জন্য; PR-AUC 0.775
13	তিনটা ঝুঁকির সীমা?	32.5°C, 12,800 MW, 100 MW gap
14	Crisis memory কী?	শান্ত বছরে retrain করা model নতুন crisis-এ কম সতর্ক; frozen model ভালো করেছে
15	Disproportionality-র সূত্র?	Load shedding-এ ভাগ ÷ demand-এ ভাগ
16	2025-এ Gini কেন সবচেয়ে বেশি?	ছোট ঘাটতির দিনে কাটা প্রায় একা Mymensingh-এ পড়ে
17	Zone premium causal কিনা?	না; model-এ না থাকা কারণও এর ভেতরে থাকতে পারে
18	"প্রথম study" বলি না কেন?	Rahman et al. 2016 আর Arifuzzaman 2026 আগে করেছে

আমার প্রস্তুতি:

- [ ] Slide 2 আর 3-এর পেছনের অংশ পড়েছি
- [ ] Metric আর p-value নিজের ভাষায় বোঝাতে পারি
- [ ] Two-crisis আর crisis memory বোঝাতে পারি
- [ ] Order of shedding দিয়ে 2025-এর Gini ব্যাখ্যা করতে পারি
- [ ] উপরের ১৮টা প্রশ্নের উত্তর না দেখে দিতে পারি